Huiswerkopdracht Odura

Sander van den Berg

April 13, 2026

1 A: Data-acquisitie en -verkenning

Voor de data over de day-ahead energieprijzen heb ik gebruik gemaakt van het ENTSO-E Transparancy Platform. Deze data is heeft op sommige dagen data per kwartier, maar op andere dagen is dat niet zo. Op deze dagen waar de data niet volledig is genereer ik nieuwe punten door te interpoleren tussen de bestaande.

1.1 Exogene variabelen

Als exogene variabelen gebruik ik de weerdata van het KNMI. Hierbij kijk ik naar de gemiddelde windsnelheid (FH), Temperatuur (T), Duur van de zoneschijn (SQ) en totale straling (Q). Deze keuze van data zorgt ervoor dat ik goed in staat zou moeten zijn om te kunnen voorspellen hoeveel wind of zonneenergie er opgewekt kan worden. De temperatuur kan ook een proxy vormen om de nodige verwarming of ventilatie te voorspellen, wat ook de energieprijs kan voorspellen.

Deze data is per uur en gaat telkens over de volledige duur van het uur. Om deze te kunnen vergelijken met de energieprijzen per kwartier heb ik nieuwe datapunten gegenereerd die de waarde van het volgende uur in de data overnemen omdat die data geldt voor het hele voorgaande uur.
De data was ook nog niet gebonden aan een tijdzone en er was nog geen zomer en wintertijdwisseling in opgenomen. Die heb ik ook toegevoegd.

1.2 Data-eigenschappen

Na de bovengenoemde aanpassingen kijken we naar de prijsdata. In figuur 1 zien we de gemiddelde prijs per maand. Het tweede deel van de figuur geeft per maand gemiddelde minimum en maximumprijs per dag aan. Een groot verschil tussen het minimum en maximum zou hier waarschijnlijk betekenen dat er met de batterij winst te maken is.

Hier valt op dat de prijs het hoogst is in de winter tussen november en maart. Er lijkt ook een piek te zijn in Juli, maar die past niet in een verdere trend, dus dit kan mogelijk verklaard worden door incidentele observaties uit 2025 die niet elk jaar plaatsvinden.

In figuur 2 zien we de Spearman correlatie tussen de prijs en de verschillende variabelen. Hier valt op dat alle variabelen een negatieve correlatie hebben met de prijs. Dat betekent dat de prijs daalt als de waarden van de variabelen stijgen. Alle variabelen hebben een correlatie met de prijs, maar voor geen van deze variabelen is de correlatie bijzonder sterk.

De variabelen hebben onderling ook correlaties en vooral de globale straling (Q) en hoeveelheid zonneschijn (SQ) zijn sterk gecorreleerd, maar daar kunnen de modellen die ik later gebruik mee omgaan.

2 B: Prijsvoorspelling

Ik heb gekozen om het Elastic Net model en het XGBoost model te gebruiken om twee verschillende soorten modellen te testen.

Figure 1: De gemiddelde energieprijs per maand. De tweede grafiek geeft ook het dag minimum en maximum aan.

Een Elastic net model is een vorm van een lineaire regressie waarbij een gewone regressie wordt gecombineerd met Lasso (L1) en Ridge (L2) methoden. Dit betekent dat het model bestaat uit 3 componenten:

1. De regressiefout (RSS): deze compontent wordt gevormd door te kijken naar welke feature combinaties in historische data het best een correlatie hebben gehad met de energieprijzen. Hier wordt gebruik gemaakt van de som van kwadraten, dus een enkele hoge uitschieter wordt meer bestraft dan meerdere kleinere uitschieters.

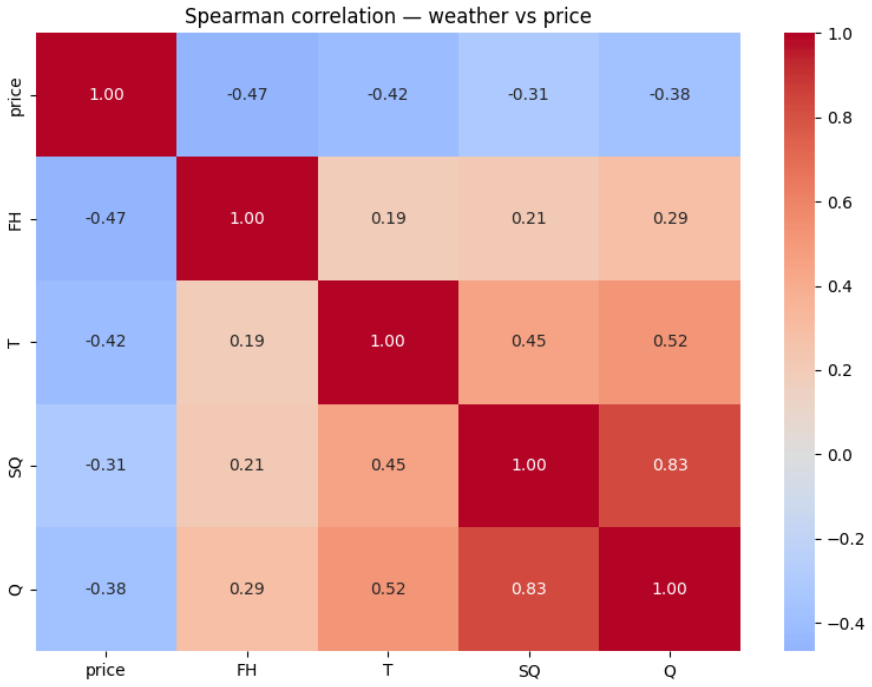

Figure 2: De spearman-correlatie tussen de verschillende variabelen

2. De Lasso (L1) strafterm: Er wordt van elke coefficient die uit de RSS komt een bepaalde factor afgetrokken. Hierdoor kunnen features die nauwelijks belang hebben op 0 komen te staan.

3. De Ridge (L2) straterm: Elke coefficiënt wordt vermenigvuldigd met een schaalfactor. Dit raakt voormaelijk de grotere coefficiënten.

Het andere gebruikte model is het XGboost model wat gebruik maakt van gradient boosting. Dit model maakt gebruik van een verzameling beslisbomen op basis van de features. Er wordt eerst een eerste basisvoorspelling gemaakt en die wordt vervolgens stap voor stap verbeterd door een beslisboom te trainen die de fouten van de huidige voorspelling verminderd. Deze individuele beslisbomen gebruiken wel de L1 en L2 termen die net besproken zijn, maar het uiteindelijke resultaat is dan de som van al die beslisbomen.

2.1 Gebruikte features en metrieken

Als features gebruiken we voornamelijk de weerdata van het KNMI. Hierbij kijken we voornamelijk naar de gemiddelde windsnelheid (FH), Temperatuur (T), Duur van zonneschijn in het uur (SQ) en de totale straling (Q).
Naast deze features, gebruik ik ook een aantal features gebaseerd op de tijd om periodieke patronen in de data te kunnen detecteren. Hiervoor kijk ik naar het uur (in de dag), de dag (in de week), de maand (in het jaar), het kwartaal en of het weekend is.
Tenslotte willlen we graag recente trends in prijs kunnen detecteren. Hiervoor gebruiken we lag features en voortschrijdende gemiddelden. We kijken voor lag naar de prijs op 1 dag en 1 week terug. Voor voortschrijdende gemiddelde gebruik ik het gemiddelde van de prijs in de week die start 1 dag voor het voorspelmoment en het gemiddelde van de 3 dagen voor het voorspelmoment.

Om de resultaten te analyseren gebruik ik 3 metrieken: MAE, RMSE en Spearman Rank (rho). MAE geeft de gemiddelde fout aan, RMSE de gemiddelde kwadratische fout en Spearman rank is een metriek die aangeeft of de voorspelling verschillende tijden op de goede volgorde zet. Dit laatste is zeer belangrijk voor onze specificieke toepassing omdat het bepaalt op welk tijdstip wel en niet energie wordt ingekocht.

2.2 Resultaten

Voor de resultaten die in deze sectie staan zijn de verschillende modellen getraind op de data van de 180 dagen voor het voorspellingsmoment. Vervolgens worden ze vergeleken op de voorspelling die gemaakt wordt over een periode van 4 dagen na het voorspelmoment. Omdat alleen gebruik gemaakt is van de data voor het jaar 2025 betekent dat dat alleen de maanden vanaf Juli voorspeld zijn.
De twee gebruikte modellen worden verder vergeleken met een naïef model dat is verkregen door te kijken naar de energieprijs op hetzelde tijdstip op de dag voor het voorspelmoment.

Figure 3: De resultaten voor de verschillende metrieken voor de dagen in het jaar

De resultaten van de verschillende modellen kunnen worden gezien in figuur 3. Hier valt het vooral op dat het naïeve model in alle metrieken sterke pieken heeft die niet in de andere modellen voorkomen. Ook zien we dat beide modellen het vrijwel altijd beter doen dan het naïeve model. XGBoost lijkt het meestal beter te doen dan het Elastic Net model, maar dat is niet altijd zo.

model	gemiddelde mae	gemiddelde msae	gemiddelde rho
XGBoost	15.50	573.05	0.828
Elastic Net	17.39	622.52	0.770
naïef	22.46	1211.28	0.685

Table 1: Gemiddelde waarden van de verschllende metrieken.

In tabel 1 zien we het gemiddelde resultaat over alle dagen die in de vorige figuur stonden. Hieruit blijkt dat XGBoost het inderdaad significant beter doet dan Elastic Net, maar dat de gemiddelde MAE en MSAE niet heel ver van elkaar af liggen. De verbetering in Spearman rank is echter wel noemenswaardig gezien het belang daarvoor op de latere batterij-optimalisatie.

2.3 Van model naar productie

Om een model als één van deze in productie te nemen moeten een aantal belangrijke stappen gezet worden. Eerst moet het model beter worden getraind om meer gevarieerde data: een half jaar is eigenlijk niet genoeg om verschil te kunnen maken tussen seizoenspatronen en incidentele schommelingen gebaseerd op de acctualiteiten van één jaar.
Ook moet het model verder gevalideerd worden op meer datasets met bijvoorbeeld onverwachte schommelingen die niet elk jaar voorkomen.
In verbinding met de bovenstaande punten moet er waarschijnlijk ook gekeken worden naar andere features zoals bijvoorbeeld gasprijzen die ook belangrijk zijn voor de energiemarkt en daarnaast meebewegen met de actualiteiten.
Het model zal ook periodiek hertraind moeten worden. Voor de huidige tests werd een vrij korte voorspelhorizon gebruikt (1 of 4 dagen). Voor een langere termijn is het nog niet geschikt. Dit is in het bijzonder een probleem als data vertraagd is. Als data van ENTSO-E enkele dagen vertraagd is kan daar waarschijnlijk nog mee om worden gegaan, maar als het langer wordt dan zal op een gegeven moment gekeken moeten worden naar andere bronnen of benaderingen.

3 C: Batterij-optimalisatie

Voor het opstellen van een optimale laad-/ontlaadplanning zijn er verschillende methoden. Ik heb besloten door het probleem om te zetten in een Linear Program (LP). Ik heb deze werkwijze gekozen vanwege verschillende redenen.

1. Een LP kan relatief makkelijk worden uitgebreid met eventuele verdere beperkingen.
2. Alle variabelen zijn reeële getallen. Dit betekent dat een LP gebruikt kan worden in plaats van een MIP (mixed integer program) omdat er geen geheeltallige oplossingen nodig zijn. LP's zijn in polynomiale tijd oplosbaar en dus zorgt dit voor een efficiënte oplossing.
3. Een LP is een bewezen methode die altijd een optimale uitkomst vindt als die bestaat.

Om de LP te modelleren en op te lossen heb ik twee verschillende implementaties gemaakt: één in Python en een andere in C#. Het Python model gebruikt de library pyomo om het model op te stellen. Dit is een algemene library voor LP/MIP problemen, wat betekent dat er in een later stadium gekozen kan worden tussen verschllende LP/MIP-solvers. Voor dit relatief kleine probleem was de ingebouwde *GLPK* solver voldoende. In C# heb ik de Google OR-Tools library gebruikt. Ook deze library heeft meerdere solvers, waarvan ik in de ingebouwde *GLOP* solver heb gekozen.

3.1 De batterij-optimalisatie LP

Om het model op te lossen als een LP visualiseren we het eerst als een flow zoals is te zien in figuur 4. In deze figuur gaan we uit van N intervallen, waarin er in elk interval energie de batterij in of uitgaat.

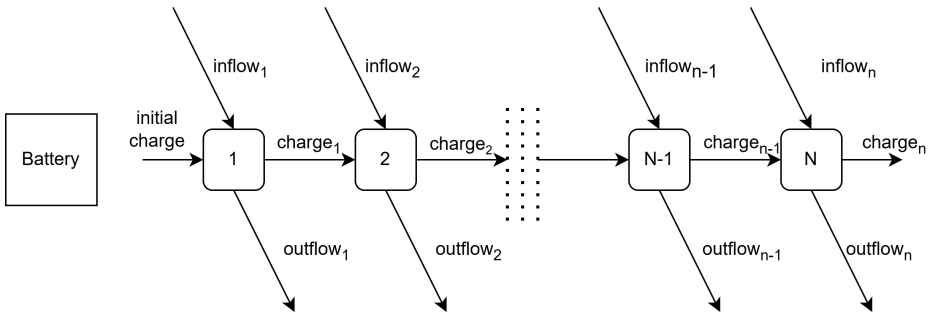

Figure 4: Een flowrepresentatie van het batterij-optimalisatieprobleem.

Deze flowrepresentatie kan vervolgens omgezet worden in een LP door de pijlen in de figuur te zien als de variabelen waarvoor we een waarde moeten vinden. Deze variabelen en de parameters van het model staan in tabel 2.

symbool	betekenis
i_t	De hoeveelheid energie die op tijdens interval t van het netwerk afgenomen wordt in MW.
o_t	De hoeveelheid energie die tijdens interval t de batterij verlaat in MW.
c_t	De hoeveelheid energie die aan het einde van interval t in de batterij zit in MWh.
p_i	De prijs van energie in interval t in MWh.
d	De degradatiekosten van de batterij in euro per ontladen MWh.
c_{start}	De hoeveelheid energie in de batterij aan de start van interval 0 in MWh.
max_c	De maximale hoeveelheid energie in de batterij in MWh.
min_c	De minimale hoeveelheid energie in de batterij in MWh.
c_{change}	De maximale hoeveelheid energie die in een tijdstip van het netwerk kan worden afgenomen of aan het netwerk kan worden geleverd in MW.
e	De round-trip efficiency van de batterij.
T_{length}	De duur van de tijdsintervallen in uren.
t_0	Eerste tijdsinterval.
T	De verzameling tijdsintervallen. Op volgorde.

Table 2: De beslissingsvariabelen, parameters en verzamelingen in het model.

Nu we de variableen en parameters hebben stellen we het model op als een LP waarin we de opbrengst maximaliseren. Dit model ziet er uit zoals hieronder is weergegeven. Het bestaat uit 3 delen. Regel 1 geeft de kostenfunctie weer, regels 2 en 3 beschrijven de flowbeperkingen en regels 4 tot 6 geven het domein van de verschillende variabelen.

De kostenfunctie bestaat uit 3 delen:

1. Als stroom wordt verkocht wordt er p_t winst gemaakt per verkochte MWh. Deze hoeveelheid MWh kan gevonden worden door de hoeveelheid stroom die de batterij verlaat (o_t te vermenigvuldigen met de lengte van het interval (T_{length}). Er gaat ook een deel verloren aan de roud trip efficiency.

2. Als er stroom de batterij verlaat zijn er degradatiekosten.

3. Als er stroom wordt ingekocht wordt kost dat p_i per MWh.

De flowbeperkingen beschrijven wat er gebeurt in elk tijdsinterval. Er wordt gekeken naar hoeveel stroom er al is en hoeveel er geladen of ontladen wordt.

$$\max \sum_{t \in T} (e * p_t - d) * T_{length} * o_t - p_t * T_{length} * i_t \tag{1}$$

$$c_{start} + T_{length} * \sqrt{e} * i_0 - T_{length} * o_0 = c_0 \tag{2}$$

$$c_{t-1} + T_{length} * \sqrt{e} * i_t - T_{length} * o_t = c_t \qquad \forall t \in T \ \{t_0\} \tag{3}$$

$$i_t \in [0, c_{change}] \tag{4}$$

$$o_t \in [0, \frac{c_{change}}{\sqrt{e}}] \tag{5}$$

$$c_t \in [min_c, max_c] \tag{6}$$

Nu het model compleet is kan dat in een solver worden gezet en vervolgens worden opgelost.

3.2 Resultaten

Als we de batterij optimaal gebruiken volgens de planning die de solver geeft komen we uit op figuur 5 (hierin geld wel de incorrecte aanname dat de batterij aan de start van elke dag op minimaal staat). Hierin is te zien dat er een aantal dagen zijn waarop het helemaal niet voordelig is om überhaubt de

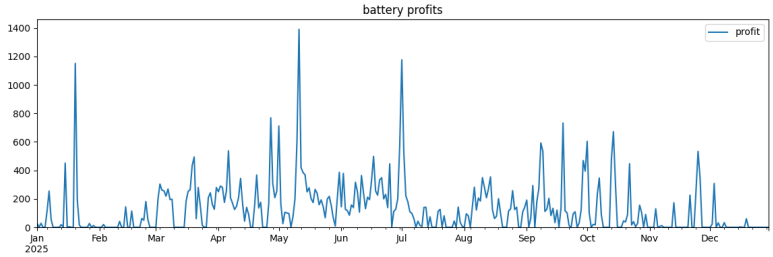

Figure 5: De winst per dag voor de batterij met optimaal gebruik

batterij te gebruiken. Dit komt onder andere doordat de degradatiekosten ervoor zorgen dat het pas voordelig is als er een verschil in prijs is van minstens 80 euro per MWh.

Dit kunnen we verder vergelijken met een niet perfecte voorspelling van de energieprijzen zoals is gedaan in figuur 6. Hierin zien we dat dit op veel momenten zorgt voor een significante daling in winst.

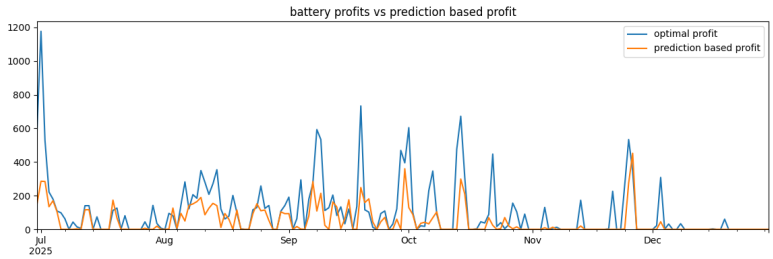

Figure 6: De winst voor de batterij met optimaal gebruik vergeleken met gebruik op basis van de voorspellingen uit het XGBoost algoritme

De totale winst van de batterij over deze tweede helft van het jaar is €19404.77 euro. In contrast wordt met de slechtere voorspelling maar €8609.15 euro winst gemaakt. Dit is meer dan een halvering ten opzichte van het originele resultaat.